

在 SLAM 系统的时候，传感器数据在不断增加，例如，摄像头在不断地采集图像数据，因此，被优化的变量也在不断增加。当被优化的变量维度增加到一定程度时，势必出现在下一个传感器数据来临时，上一个传感器数据还没有处理完成的情况。因此需要限制状态变量的规模。考虑目标函数：

$$\mathbf{L}(\delta \mathbf{x}_p, \delta \mathbf{x}_m) = \left[f(\mathbf{x}_p, \mathbf{x}_m) + \mathbf{J}_{\mathbf{x}_p} \delta \mathbf{x}_p + \mathbf{J}_{\mathbf{x}_m} \delta \mathbf{x}_m \right]^\top \mathbf{W} \left[f(\mathbf{x}_p, \mathbf{x}_m) + \mathbf{J}_{\mathbf{x}_p} \delta \mathbf{x}_p + \mathbf{J}_{\mathbf{x}_m} \delta \mathbf{x}_m \right] \quad (1)$$

令目标函数的一阶导为 0，可以得到正规方程：

$$\begin{bmatrix} \Lambda_p & \Lambda_{pm} \\ \Lambda_{pm}^T & \Lambda_m \end{bmatrix} \begin{bmatrix} \delta \mathbf{x}_p \\ \delta \mathbf{x}_m \end{bmatrix} = \begin{bmatrix} \mathbf{b}_p \\ \mathbf{b}_m \end{bmatrix} = - \begin{bmatrix} \mathbf{J}_p^\top \mathbf{W} f \\ \mathbf{J}_m^\top \mathbf{W} f \end{bmatrix} \quad (2)$$

根据前文的描述，正规方程的求解可以用舒尔补加速：

$$\begin{bmatrix} \Lambda_p - \Lambda_{pm} (\Lambda_m)^{-1} \Lambda_{pm}^T & 0 \\ \Lambda_{pm}^T & \Lambda_m \end{bmatrix} \begin{bmatrix} \delta \mathbf{x}_p \\ \delta \mathbf{x}_m \end{bmatrix} = \begin{bmatrix} \mathbf{b}_p - \Lambda_{pm} (\Lambda_m)^{-1} \mathbf{b}_m \\ \mathbf{b}_m \end{bmatrix} \quad (3)$$

不妨假设 \mathbf{x}_m 为需要被边缘化的变量。变量在被边缘化之后，残差对于变量的雅可比不再变化，即线性化点不再改变，其对应的信息矩阵 Λ_m 不再变化。令 $\Lambda_{\text{prior}} = -\Lambda_{pm} (\Lambda_m)^{-1} \Lambda_{pm}^T$, $\mathbf{b}_{\text{prior}} = -\Lambda_{pm} (\Lambda_m)^{-1} \mathbf{b}_m$ ，则正规方程变为：

$$(\Lambda_p + \Lambda_{\text{prior}}) \delta \mathbf{x}_p = \mathbf{b}_p + \mathbf{b}_{\text{prior}} \quad (4)$$

并且有：

$$\frac{\partial \mathbf{b}_{\text{prior}}}{\partial \mathbf{x}_p} = \frac{\partial (-\Lambda_{pm} (\Lambda_m)^{-1} \mathbf{b}_m)}{\partial \mathbf{x}_p} \quad (5)$$

$$= \frac{(-\Lambda_{pm} (\Lambda_m)^{-1}) \partial \mathbf{b}_m}{\partial \mathbf{x}_p} \quad (6)$$

$$= \frac{(-\Lambda_{pm} (\Lambda_m)^{-1}) \mathbf{J}_m^\top \mathbf{W} \partial f}{\partial \mathbf{x}_p} \quad (7)$$

$$= (-\Lambda_{pm} (\Lambda_m)^{-1}) \mathbf{J}_m^\top \mathbf{W} \mathbf{J}_p \quad (8)$$

$$= (-\Lambda_{pm} (\Lambda_m)^{-1}) \Lambda_{mp} \quad (9)$$

$$= \Lambda_{\text{prior}} \quad (10)$$

变量被边缘化后，根据变量被边缘化时的状态计算出来的 Λ_{prior} 不再改变，只需要对 $\mathbf{b}_{\text{prior}}$ 更新，即边缘化后，若 LM 算法某一次迭代计算出来的步长为 $\delta \mathbf{x}_p$ ，则 $\mathbf{b}_{\text{prior}}$ 需要使用一阶泰勒近似更新为 $\mathbf{b}_{\text{prior}} + \Lambda_{\text{prior}} \delta \mathbf{x}_p$ ，因此变量被边缘化的过程就是计算 Λ_{prior} 和 $\mathbf{b}_{\text{prior}}$ 的过程，即正规方程变为：

$$(\Lambda_p + \Lambda_{\text{prior}}) \delta \mathbf{x}_r = \mathbf{b}_p + \mathbf{b}_{\text{prior}} + \Lambda_{\text{prior}} \Delta \mathbf{x}_r \quad (11)$$

上式等价于在边缘化后剩下的残差项的基础上，新加一个残差 $\frac{1}{2}(\bar{\mathbf{f}}_0 + \bar{\mathbf{J}}_{prior}\mathbf{x}_r)^\top(\bar{\mathbf{f}}_0 + \bar{\mathbf{J}}_{prior}\mathbf{x}_r)$ ，其中 $\bar{\mathbf{J}}_{prior}^\top \bar{\mathbf{J}}_{prior} = -\mathbf{\Lambda}_{prior}$ ，考虑 $\mathbf{\Lambda}_{prior}$ 是一个对称矩阵，可以对 $\mathbf{\Lambda}_{prior}$ 进行特征值分解得到 $\mathbf{J}_{prior}^{-\top} \mathbf{J}_{prior}^{-} = \mathbf{U}\mathbf{S}\mathbf{U}^\top$ ，于是 $\bar{\mathbf{J}}_{prior} = \mathbf{S}^{\frac{1}{2}}\mathbf{U}^\top$ 。




图 1 原始目标函数 $f(x, y) = \frac{1}{2}(xy - 1)^2$




图 2 在 (2, 2) 处线性化后的目标函数




图 3 在 (1.1, 1.1) 处边缘化后的目标函数




图 4 在 (1.5, 1.5) 处边缘化后的目标函数

为了更进一步观察边缘化对优化的影响，以非线性函数 $\frac{1}{2}f(x, y) = (xy - 1)^2$ 为例，我们在图1中画出了原始目标函数的图像，其中横坐标为 x ，纵坐标为 y ，函数值大于 1 的函数值统一为黄色，显然该目标函数的解空间为 $xy = 1$ ，对于该目标函数而言，变量 x 和 y 都是不可观的。在图2中画出了 $f(x, y) = \frac{1}{2}(xy - 1)^2$ 在 (2, 2) 处线性化后的图像，线性化后目标函数变为 $\frac{1}{2}(f(2, 2) + 2(x - 2) + 2(y - 2))^2$ ，注意此时变量 x 和变量 y 依然是不可观测的。在图3中画出了目标函数在 (1.1, 1.1) 处将变量 y 边缘化后的图像，此时目标函数变为 $f(x, y) = \frac{1}{2}(1.1x - 1)^2 + \frac{1}{2}(f(1.1, 1.1) + 1.1(x - 1.1))^2$ ，在图4中画出了目标函数在 (1.5, 1.5) 处将变量 y 边缘化后的图像，此时目标函数变为 $f(x, y) = \frac{1}{2}(1.5x - 1)^2 + \frac{1}{2}(f(1.5, 1.5) + 1.5(x - 1.5))^2$ ，并且无论是在 (1.1, 1.1) 处边缘化，还是 (1.5, 1.5) 处边缘化，目标函数关于 x 的解都是唯一的，也就是 x 的可观性发生了变化，本来它是不可观的，经过边缘化后变得可观了，具体来说，是信息矩阵的秩发生了变化^[1]。在某些情况下，变量的可观性的变化对最终的优化结果有负面影响，

若固定线性化点以及雅可比后变量的可观性不会发生变化，因此在^[2,3]等论文中，采用了 FEJ(First Estimate Jacobian) 策略^[4]。但 FEJ 对精度的影响不一定是正面的，例如在 Vins-Mono^[5] 对 VIO 的实现中，作者声称即便不采用 FEJ 策略，在不可观的自由度上也不会有明显的漂移，反而采用 FEJ 策略后，系统的精度会有一定的下降。




图 5 边缘化 x_{m1}




图 6 边缘化 x_{p1}




图 7 边缘化中信息矩阵的变化过程，在确定需要边缘化的变量之后，需要首先将它们移动到信息矩阵的右下角，然后使用舒尔补更新信息矩阵，得到的信息矩阵将作为先验信息参与到后面的优化中。

边缘化除了会改变变量的解空间，让本不可观的变量变得可观外，还会破坏信息矩阵的稀疏性，在图??中，我们给出了一个 VIO 例子，该例子中有 3 个相机，3 个特征点，相机 x_{p1} 可以观测到 1 个特征点，相机 x_{p2} 和 x_{p3} 都可以观测到 2 个特征点，在图5中画出了边缘化 x_{m1} 后图的变化，在图6中画出了边缘化 x_{p1} 后图的变化，从图上来看，边缘化一些变量后会让剩下的变量之间的连接更为稠密。在图7给出了 Λ_{prior} 的计算过程示意图，如前文所说， Λ_{prior} 会作为先验信息加到后续优化的信息矩阵中。显然，最初的信息矩阵 x_{m1}, x_{m2}, x_{m3} 对应的信息矩阵是对角矩阵，它是稀疏的，而 Λ_{prior} 中 x_{m1}, x_{m2}, x_{m3} 对应的信息矩阵却不是对角的，对它的逆的求解的时间复杂度远大于对对角矩阵求逆的时间复杂度。也就是说边缘化会导致信息矩阵变得更为稠密。在实际操作中，为了维持信息矩阵的稀疏性，通常需要用一些策略丢弃掉一些信息，例如，可以只边缘化相机位姿，对于特征点的信息矩阵全部丢弃。

参考文献

- [1] DONG-SI T C, MOURIKIS A I. Consistency analysis for sliding-window visual odometry[C]//2012 IEEE International Conference on Robotics and Automation. .[S.l.]: [s.n.] , 2012:5202–5209.
- [2] DONG-SI T C, MOURIKIS A I. Motion tracking with fixed-lag smoothing: Algorithm and consistency analysis[C]//2011 IEEE International Conference on Robotics and Automation. .[S.l.]: [s.n.] , 2011:5655–5662.
- [3] LEUTENEGGER S, LYNEN S, BOSSE M, et al. Keyframe-based visual–inertial odometry using non-linear optimization[J]. The International Journal of Robotics Research, 2015, 34(3):314–334.
- [4] HUANG G P, MOURIKIS A I, ROUMELIOTIS S I. A first-estimates Jacobian EKF for improving SLAM consistency[C]//Experimental Robotics. .[S.l.]: [s.n.] , 2009:373–382.
- [5] QIN T, LI P, SHEN S. Vins-mono: A robust and versatile monocular visual-inertial state estimator[J]. IEEE Transactions on Robotics, 2018, 34(4):1004–1020.