

某一时刻，VIO 的状态集合为相机的位姿 $\{\mathbf{x}_{\mathbf{p}_j}, 1 \leq j \leq m\}$ ，以及特征点的位姿 $\{\mathbf{x}_{\mathbf{m}_i}, 1 \leq i \leq m\}$ 令

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_{\mathbf{p}} \\ \mathbf{x}_{\mathbf{m}} \end{bmatrix} = \begin{bmatrix} \mathbf{x}_{\mathbf{p}_1} \\ \vdots \\ \mathbf{x}_{\mathbf{p}_m} \\ \mathbf{x}_{\mathbf{m}_1} \\ \vdots \\ \mathbf{x}_{\mathbf{m}_n} \end{bmatrix} \quad (1)$$

并且有：

$$\mathbf{x}_{\mathbf{p}_j} = f_j(\mathbf{x}_{\mathbf{p}_{j-1}}, \mathbf{u}_j) + \mathbf{w}_j \quad (2)$$

上式描述了相邻时刻相机的位姿的约束关系，这个约束关系可以从预积分中得到，亦可以从相机的运动模型中得到。 $\mathbf{w}_j \sim \mathcal{N}(0, \mathbf{Q}_j)$ 是高斯白噪声。当 \mathbf{p}_{j-1} 作为先验时， $\mathbf{x}_{\mathbf{p}_j}$ 服从正态分布， $p(\mathbf{x}_{\mathbf{p}}) = \mathcal{N}(\mu_{\mathbf{p}}, \mathbf{Q})$ ，其中

$$\mu_{\mathbf{p}} = f(\mathbf{x}) = \begin{bmatrix} \mathbf{x}_{\mathbf{p}_1} \\ f_1(\mathbf{x}_{\mathbf{p}_1}, \mathbf{u}_2) \\ \vdots \\ f_m(\mathbf{x}_{\mathbf{p}_{m-1}}, \mathbf{u}_m) \end{bmatrix}, \mathbf{Q} = \begin{bmatrix} \mathbf{Q}_1 & & \\ & \ddots & \\ & & \mathbf{Q}_m \end{bmatrix} \quad (3)$$

另外摄像机，加速度计等传感器会提供一些量测信息：

$$\mathbf{z}_{ij} = h_{ij}(\mathbf{x}_{\mathbf{m}_i}, \mathbf{x}_{\mathbf{p}_j}) + \mathbf{v}_{ij} \quad (4)$$

其中 $\mathbf{v}_{ij} \sim \mathcal{N}(0, \mathbf{R}_{ij})$ 。在基于非线性最小二乘的框架中，记：

$$g(\mathbf{x}) = \begin{bmatrix} \mathbf{z} - h(\mathbf{x}) \\ \mathbf{x}_{\mathbf{p}} - f(\mathbf{x}_{\mathbf{p}}) \end{bmatrix} \quad (5)$$

优化的目标是使下式最小，注意 \mathbf{W} 为对称矩阵，即 $\mathbf{W} = \mathbf{W}^T$ ：

$$\ell(\mathbf{x}) = \frac{1}{2} (g(\mathbf{x})^T \mathbf{W} g(\mathbf{x})), \mathbf{W} = \begin{bmatrix} \mathbf{R}^{-1} & 0 \\ 0 & \mathbf{Q}^{-1} \end{bmatrix} \quad (6)$$

在高斯牛顿算法的框架下，在每一次迭代时，目标是求解 h 使得下式最小：

$$\ell(\mathbf{x} + \mathbf{h}) = \frac{1}{2} (g(\mathbf{x}) + \mathbf{J}_{\mathbf{g}} \mathbf{h})^T \mathbf{W} (g(\mathbf{x}) + \mathbf{J}_{\mathbf{g}} \mathbf{h}) \quad (7)$$

其中 $\mathbf{J}_g \mathbf{h} = \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$,

$$\frac{\partial \ell(\mathbf{x} + \mathbf{h})}{\partial \mathbf{x}} = \frac{1}{2} g(\mathbf{x})^T \mathbf{W} g(\mathbf{x}) + g(\mathbf{x})^T \mathbf{W} \mathbf{J}_g \mathbf{h} + \frac{1}{2} \mathbf{h}^T \mathbf{J}_g^T \mathbf{W} \mathbf{J}_g \mathbf{h} \quad (8)$$

$$\frac{\partial^2 \ell(\mathbf{x} + \mathbf{h})}{\partial \mathbf{x}^2} = \mathbf{J}_g^T \mathbf{W} g(\mathbf{x}) + \mathbf{J}_g^T \mathbf{W} \mathbf{J}_g \mathbf{h} \quad (9)$$

令上式等于 0，并令 $\mathbf{H} = \mathbf{J}_g^T \mathbf{W} \mathbf{J}_g$ ，得到正规方程 (Normal Equation):

$$\mathbf{H} \mathbf{h} = -\mathbf{J}_g^T \mathbf{W} g(\mathbf{x}) \quad (10)$$

将 \mathbf{H} 展开:

$$\mathbf{H} = \begin{bmatrix} \mathbf{J}_f \\ \mathbf{J}_h \end{bmatrix}^T \begin{bmatrix} \mathbf{R}^{-1} & 0 \\ 0 & \mathbf{Q}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{J}_f \\ \mathbf{J}_h \end{bmatrix} \quad (11)$$

$$= \mathbf{J}_f \mathbf{R}^{-1} \mathbf{J}_f + \mathbf{J}_g \mathbf{Q}^{-1} \mathbf{J}_g \quad (12)$$

$$= \begin{bmatrix} \Lambda_p & \Lambda_{pm} \\ \Lambda_{pm}^T & \Lambda_m \end{bmatrix} \quad (13)$$

因此正规方程可写成以下的形式:

$$\begin{bmatrix} \Lambda_p & \Lambda_{pm} \\ \Lambda_{pm}^T & \Lambda_m \end{bmatrix} \begin{bmatrix} \delta \mathbf{x}_p \\ \delta \mathbf{x}_m \end{bmatrix} = \begin{bmatrix} \mathbf{b}_p \\ \mathbf{b}_m \end{bmatrix} \quad (14)$$




图 1 一个 VIO 的简单例子，图中的节点表示待优化的变量，边表示节点之间的误差项，第一时刻的相机 \mathbf{x}_{p1} 能观测到特征点 \mathbf{x}_{m1} ，在第二时刻的相机 \mathbf{x}_{p2} 能观测到特征点 \mathbf{x}_{m2} 和特征点 \mathbf{x}_{m3} ，在第三时刻的相机 \mathbf{x}_{p3} 能观测到特征点 \mathbf{x}_{m2} 和特征点 \mathbf{x}_{m3} ，这些观测对应 $\mathbf{r}_1 \cdots \mathbf{r}_7$ 共七组误差。注意

在图1中给出了一个 VIO 的简单例子，第一时刻的相机 \mathbf{x}_{p1} 能观测到特征点 \mathbf{x}_{m1} ，在第二时刻的相机 \mathbf{x}_{p2} 能观测到特征点 \mathbf{x}_{m2} 和特征点 \mathbf{x}_{m3} ，在第三时刻的相机 \mathbf{x}_{p3} 能

观测到特征点 \mathbf{x}_{m2} 和特征点 \mathbf{x}_{m3} , 状态变量依次为 $\mathbf{x}_{p1}, \mathbf{x}_{p2}, \mathbf{x}_{p3}, \mathbf{x}_{m1}, \mathbf{x}_{m2}, \mathbf{x}_{m3}$, 其中共有七条边, 对应误差为 $\mathbf{r}_1 \cdots \mathbf{r}_7$, $\mathbf{r}_i, 1 \leq i \leq 7$ 对应的信息矩阵为 $\Lambda_i, 1 \leq i \leq 7$, 其中, Λ_i 为:

$$\Lambda_1 = \begin{bmatrix} \mathbf{J}_{\mathbf{x}_{p1}}^{r1 \top} \mathbf{W}_{\mathbf{r}_1} \mathbf{J}_{\mathbf{x}_{p1}}^{r1} & 0 & 0 & \mathbf{J}_{\mathbf{x}_{p1}}^{r1 \top} \mathbf{W}_{\mathbf{r}_1} \mathbf{J}_{\mathbf{x}_{m1}}^{r1} & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ \mathbf{J}_{\mathbf{x}_{m1}}^{r1 \top} \mathbf{W}_{\mathbf{r}_1} \mathbf{J}_{\mathbf{x}_{p1}}^{r1} & 0 & 0 & \mathbf{J}_{\mathbf{x}_{m1}}^{r1 \top} \mathbf{W}_{\mathbf{r}_1} \mathbf{J}_{\mathbf{x}_{m1}}^{r1} & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (15)$$

$$\dots \quad (16)$$

$$\Lambda_7 = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \mathbf{J}_{\mathbf{x}_{p3}}^{r7 \top} \mathbf{W}_{\mathbf{r}_7} \mathbf{J}_{\mathbf{x}_{p3}}^{r7} & 0 & 0 & \mathbf{J}_{\mathbf{x}_{p3}}^{r7 \top} \mathbf{W}_{\mathbf{r}_7} \mathbf{J}_{\mathbf{x}_{m3}}^{r7} \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \mathbf{J}_{\mathbf{x}_{m3}}^{r7 \top} \mathbf{W}_{\mathbf{r}_7} \mathbf{J}_{\mathbf{x}_{p1}}^{r7} & 0 & 0 & \mathbf{J}_{\mathbf{x}_{m3}}^{r7 \top} \mathbf{W}_{\mathbf{r}_7} \mathbf{J}_{\mathbf{x}_{m3}}^{r7} \end{bmatrix} \quad (17)$$

其中 $\mathbf{J}_{\mathbf{x}_j}^{r_i}$ 为 r_i 对 \mathbf{x}_j 的雅可比, $\mathbf{W}_{\mathbf{r}_i}$ 为残差项对应的权重, 该权重根据实际情况通常设置为对应残差的协方差的逆。总体的信息矩阵为: $\Lambda = \sum_{i=1}^7 \Lambda_i$ 。在图?? 中给出了这个信息矩阵累加的过程, 在图中可以看到, 每一个残差项提供的信息矩阵都是稀疏的, 最终累加得到的稀疏矩阵 Λ 也是稀疏的。




图2 信息矩阵累加过程示意图, 最后的信息矩阵 Λ 由每一个小的残差项的信息矩阵 Λ_i 累加而成, 每一个小的残差项的信息矩阵 Λ_i 是稀疏的, 最后的信息矩阵 Λ 也是稀疏的。 Λ 的稀疏性主要有两点: (1). 它的右下角子矩阵只在对角线上有元素; (2). 它的右上角矩阵和左下角矩阵互为转置关系

对于一个基于图优化的视觉里程计系统来说, 优化的大部分时间被消耗在了信息矩阵的维护和求逆上面。首先由于信息矩阵的右上角子矩阵和左下角子矩阵互为转置关系, 因此可以使用舒尔补加速矩阵的求解。另外, 由于假设特征点之间是独立的, 对其中一个特征点的观测并不会影响对其它特征点的观测, 因此信息矩阵的右下角子

矩阵的对角上的子矩阵都为对角矩阵。

根据信息矩阵的特点，将其分为四个子矩阵：

$$\mathbf{\Lambda} = \begin{bmatrix} \mathbf{\Lambda}_p & \mathbf{\Lambda}_{pm} \\ \mathbf{\Lambda}_{mp} & \mathbf{\Lambda}_m \end{bmatrix} \quad (18)$$

利用 \mathbf{H} 的性质，可以用舒尔补加速正规方程的求解：

$$\begin{bmatrix} \mathbf{\Lambda}_p - \mathbf{\Lambda}_{pm} (\mathbf{\Lambda}_m)^{-1} \mathbf{\Lambda}_{pm}^T & 0 \\ \mathbf{\Lambda}_{pm}^T & \mathbf{\Lambda}_m \end{bmatrix} \begin{bmatrix} \delta \mathbf{x}_p \\ \delta \mathbf{x}_m \end{bmatrix} = \begin{bmatrix} \mathbf{g}_p - \mathbf{\Lambda}_{pm} (\mathbf{\Lambda}_m)^{-1} \mathbf{g}_m \\ \mathbf{g}_m \end{bmatrix} \quad (19)$$

可以得到：

$$\begin{aligned} \delta \mathbf{x}_p &= (\mathbf{\Lambda}_p - \mathbf{\Lambda}_{pm} (\mathbf{\Lambda}_m)^{-1} \mathbf{\Lambda}_{pm}^T)^{-1} (\mathbf{g}_p - \mathbf{\Lambda}_{pm} (\mathbf{\Lambda}_m)^{-1} \mathbf{g}_m) \\ \delta \mathbf{x}_m &= (\mathbf{\Lambda}_m)^{-1} (\mathbf{g}_m - \mathbf{\Lambda}_{pm}^T \delta \mathbf{x}_p) \end{aligned} \quad (20)$$

根据前文的描述， $\mathbf{\Lambda}_m$ 只在对角线附近有元素，因此 $\mathbf{\Lambda}_m^{-1}$ 的计算的时间复杂度可以从 $O(n^3)$ 降低到 $O(n)$ ，而在基于 SLAM 系统中，特征点通常非常多，从数千个到数万个不等，需要优化的位姿通常较少，因此 SLAM 的稀疏性可以确保整个问题是可以被优化的。